# UNIVERSIDAD NACIONAL DEL ALTIPLANO

## FACULTAD DE INGENIERÍA MECÁNICA ELÉCTRICA, ELECTRÓNICA Y SISTEMAS

## ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMA

**Tema:**

**Evaluación de algoritmos de clustering**

**Enlace del repositorio:**

https://github.com/PattyTurpo/Clustering.git

**Curso:**

Aprendizaje Máquina

**Docente:**

Ing. Fernandez Chambi Mayenka

**Presentada por:**

Huanca Chahuara Cyntia Mariela

Turpo Quispe Patty Milagros

Carrazco Yupanqui Edilza Luz

Quispe Hualla Yuri Florentino

**Puno – Perú, 2026**

## 1. Objetivo y metodología

El objetivo es comprender la naturaleza de los modelos de clustering lineales y no lineales y cómo se evalúan con métricas de validación externa (que usan las etiquetas reales) e interna (que solo usan los datos y los clústeres encontrados). Se entrenaron **K-means**, **DBSCAN** y **SpectralClustering** sobre tres datasets: Iris, Moons y Circles. Todo el código está en el notebook del repositorio, con random_state = 42 y scikit-learn 1.9.1.

### *1.1 Métricas utilizadas*

| Tipo | Métrica | Qué mide | Mejor valor |
|---|---|---|---|
| Externa | ARI | Concordancia entre clústeres y clases reales, corregida por azar. Puede ser negativa. | Cercano a 1 (≈ 0 = azar) |
| Externa | V-measure | Media armónica de homogeneidad (cada clúster tiene una sola clase) y completitud (cada clase cae en un solo clúster). | Cercano a 1 |
| Interna | Silhouette | Cohesión frente a separación: distancia media intra-clúster contra la del clúster vecino más cercano. Rango [-1, 1]. | Cercano a 1 |
| Interna | Davies-Bouldin | Similitud promedio entre cada clúster y su vecino más parecido. | Cercano a 0 |
| Interna | Elbow (codo) | Inercia de K-means al variar k; se busca el punto donde la mejora se aplana. | Punto de inflexión |
| Interna | Calinski-Harabasz | Complementaria: dispersión entre clústeres sobre dispersión intra-clúster. | Mayor es mejor |

**Tratamiento del ruido de DBSCAN.** DBSCAN marca con -1 los puntos que considera ruido. En las métricas externas el ruido cuenta como un clúster más (así se penaliza descartar muchos puntos). Las métricas internas se calculan sin los puntos de ruido y solo si hay al menos 2 clústeres.

**Preprocesamiento.** En Iris se estandarizaron las variables con StandardScaler, porque los tres modelos usan distancias. El PCA se usó solo para graficar en 2D; los modelos se entrenaron con las 4 variables.

Como complemento se desarrolló una aplicación gráfica interactiva con el caso Circles, descrita en la sección 7.

## 2. Dataset Iris

150 flores con 4 características y 3 especies reales. *Setosa* está claramente separada, pero *versicolor* y *virginica* se solapan; esto condiciona a los tres modelos.

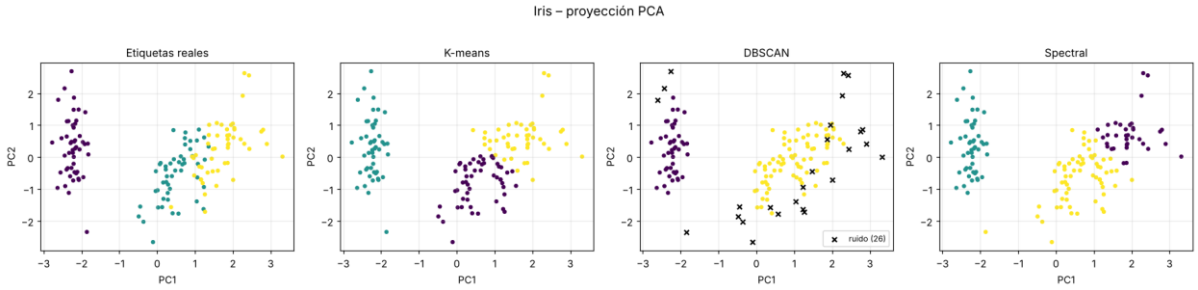



*Figura 1. Iris (proyección PCA): etiquetas reales y resultado de cada modelo. La x negra es ruido de DBSCAN.*

### *2.1 Explicación del comportamiento de los modelos*

**K-means (k = 3).** Separa *setosa* de forma perfecta (50/50) y reparte el resto en dos grupos compactos. Los errores están en la zona de solapamiento: el clúster 0 contiene 39 versicolor y 14 virginica, y el clúster 2 contiene 11 versicolor y 36 virginica. Funciona razonablemente porque Iris tiene grupos más o menos esféricos y se le dio el k correcto. El codo no es tajante: la mayor caída es de k = 1 a k = 2 (600 → 222) y hay una segunda inflexión en k = 3 (≈ 140). Además, el Silhouette favorece k = 2 (0.58 frente a 0.46 con k = 3), porque versicolor y virginica se perciben como un solo bloque. Por eso k = 3 se justifica con el conocimiento del dominio (3 especies) y no solo con las métricas.

**DBSCAN (eps = 0.6, min_samples = 5).** Encuentra solo 2 clústeres: *setosa* (46 puntos) y un bloque que fusiona versicolor y virginica (42 + 36), y marca 26 puntos (17.3 %) como ruido. DBSCAN agrupa por densidad y, entre versicolor y virginica, no hay un valle de baja densidad. Es muy sensible a eps: con eps = 0.3 el 80 % de los puntos son ruido; con eps ≥ 0.7 el ruido baja a ≤ 4 % pero siguen siendo solo 2 clústeres.

**SpectralClustering (3 clústeres, vecinos más cercanos).** Resultado muy parecido a K-means, ligeramente mejor (setosa 49/50; 47 versicolor bien asignadas). Como Iris no tiene formas complejas, el grafo de afinidad no aporta una ventaja real.

**¿Ayudó estandarizar?** No en este caso: K-means sin estandarizar da ARI = 0.73 y estandarizado 0.62. En el dataset *wine* del curso era crucial (una variable con varianza ≈ 99 166), pero en Iris todas las medidas están en cm con varianzas comparables (0.19 a 3.1). Al estandarizar, el ancho de sépalo, poco informativo, gana el mismo peso que las variables del pétalo.

### *2.2 Significado de las métricas en Iris*

| Métrica | K-means | DBSCAN | Spectral |
|---|---|---|---|
| N.º de clústeres | 3 | 2 | 3 |
| % de ruido | 0.0 | 17.3 | 0.0 |
| ARI | 0.62 | 0.471 | 0.646 |
| V-measure | 0.659 | 0.541 | 0.684 |
| Homogeneidad | 0.659 | 0.518 | 0.674 |
| Completitud | 0.66 | 0.566 | 0.694 |
| Silhouette | 0.46 | 0.642 | 0.459 |
| Davies-Bouldin | 0.834 | 0.512 | 0.822 |
| Calinski-Harabasz | 241.904 | 330.917 | 229.68 |

*Tabla 1. Métricas de validación en Iris.*

- **ARI ≈ 0.62–0.65 (K-means, Spectral):** concordancia buena pero no perfecta; el error viene de mezclar versicolor y virginica. **ARI = 0.471 (DBSCAN)** es el peor porque fusionó dos especies y envió el 17 % de los puntos a ruido.
- **V-measure 0.66–0.68:** homogeneidad ≈ 0.66 (clústeres bastante puros) y completitud ≈ 0.66–0.69. En DBSCAN la homogeneidad baja a 0.518 porque su clúster grande mezcla especies.
- **Silhouette 0.46 (K-means, Spectral):** estructura moderada, con clústeres que se tocan. **Davies-Bouldin 0.82–0.83:** aceptable (menor es mejor).
- **Silhouette 0.642 y Davies-Bouldin 0.512 (DBSCAN):** parecen los mejores, pero es una trampa. Solo se calculan con 2 clústeres y sin los puntos de ruido (justo los de la frontera difícil); separar setosa del resto es fácil e infla las métricas.
- **Lección:** la mejor agrupación según las métricas internas (DBSCAN) es la peor según las externas.

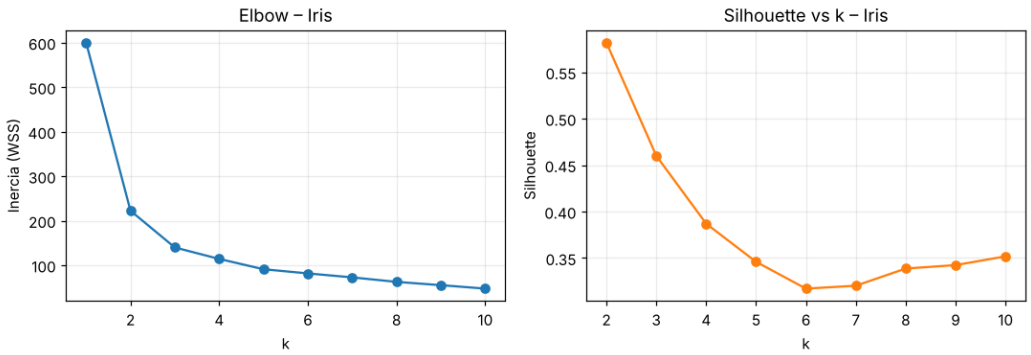



*Figura 2. Elbow y Silhouette vs k para Iris.*

## 3. Dataset sintético Moons

500 puntos en dos medias lunas entrelazadas (make_moons, noise = 0.07): dos clases no convexas y no linealmente separables.

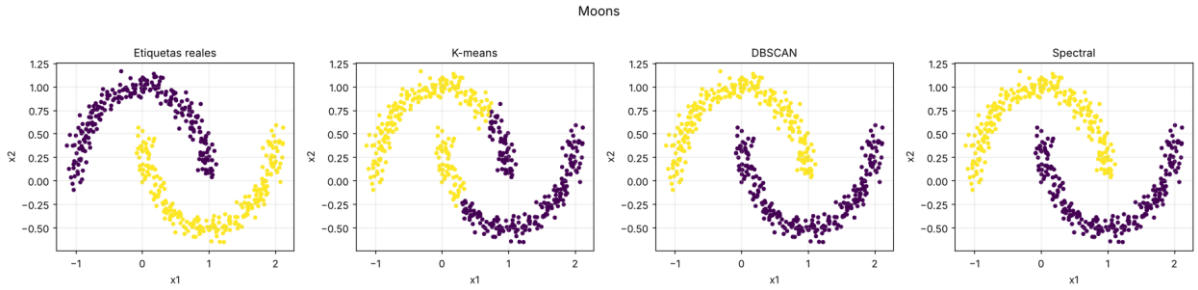



*Figura 3. Moons: etiquetas reales y resultado de cada modelo.*

### *3.1 Explicación del comportamiento de los modelos*

**K-means falla (ARI = 0.26).** Corta el plano con una recta (la mediatriz entre dos centroides), así que parte cada luna por la mitad y mezcla ambas clases. Su criterio supone grupos compactos y convexos, y el centroide de cada luna cae fuera de la propia figura. El codo tampoco ayuda: la inercia baja de forma continua (505 → 205 → 137 → 89 …) sin un codo claro.

**DBSCAN acierta (ARI = 1.0).** Con eps = 0.2 y min_samples = 5 cada luna es una cadena continua de puntos vecinos densos; DBSCAN las encadena y, como entre ambas hay un hueco, no las une. No marca ruido. Es sensible a eps: con eps = 0.1 aparecen 13 puntos de ruido (ARI ≈ 0.95), el rango estable va de ≈ 0.15 a 0.3, y con eps ≥ 0.35 las lunas se fusionan en un solo clúster (ARI = 0).

**Spectral con nearest_neighbors acierta (ARI = 1.0).** El grafo de 10 vecinos conecta cada punto solo con su entorno, de modo que hay dos componentes casi desconectados y el espectro del Laplaciano los separa. Con affinity = "rbf" y gamma = 1 falla (ARI ≈ 0.28); necesita gamma ≥ 10–20. Con 3 vecinos el grafo se rompe en demasiados trozos (ARI = 0).

### *3.2 Significado de las métricas en Moons*

| Métrica | K-means | DBSCAN | Spectral |
|---|---|---|---|
| N.º de clústeres | 2 | 2 | 2 |
| % de ruido | 0.0 | 0.0 | 0.0 |
| ARI | 0.261 | 1 | 1 |
| V-measure | 0.198 | 1 | 1 |
| Homogeneidad | 0.198 | 1 | 1 |
| Completitud | 0.198 | 1 | 1 |
| Silhouette | 0.487 | 0.332 | 0.332 |
| Davies-Bouldin | 0.785 | 1.153 | 1.153 |
| Calinski-Harabasz | 730.114 | 331.338 | 331.338 |

*Tabla 2. Métricas de validación en Moons.*

- **Externas:** ARI = V-measure = 1 en DBSCAN y Spectral significa que recuperan exactamente las dos lunas. En K-means, V-measure = 0.198 indica que sus clústeres casi no informan sobre la clase real.
- **Internas, el ranking se invierte:** K-means obtiene el mejor Silhouette (0.487), el menor Davies-Bouldin (0.785) y el mayor Calinski-Harabasz (730), pese a ser el modelo equivocado. Estas métricas miden compacidad y separación respecto a centroides, justo lo que K-means optimiza. Las lunas correctas son alargadas y se curvan una alrededor de la otra, así que tienen puntos lejanos dentro del mismo clúster y vecinos cercanos de la otra clase (Silhouette 0.332).
- **Conclusión:** con formas no convexas las métricas internas clásicas no son fiables para comparar algoritmos de familias distintas. Si hay etiquetas, deben priorizarse las externas.

## 4. Dataset sintético Circles

500 puntos en dos círculos concéntricos (make_circles, factor = 0.4, noise = 0.05). Ambas clases comparten centro, así que ninguna frontera recta ni ningún modelo basado en centroides puede separarlas.

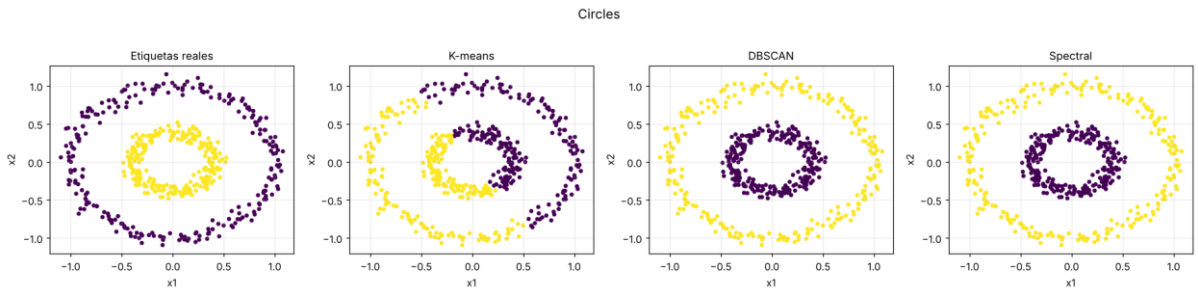



*Figura 4. Circles: etiquetas reales y resultado de cada modelo.*

### *4.1 Explicación del comportamiento de los modelos*

**K-means falla por completo (ARI ≈ 0, V-measure = 0).** Ambos círculos tienen el mismo centro; cualquier recta deja mitades de ambos en cada lado. Es el peor caso para un método basado en centroides: la partición equivale a una al azar respecto a las clases. El codo tampoco muestra un k claro (290 → 190 → 122 …).

**DBSCAN acierta (ARI = 1.0).** Cada círculo es una curva continua y densa; con eps = 0.15 los puntos de un anillo se encadenan, y el hueco entre anillos (radio 0.4 frente a 1.0) impide que se unan. Con eps = 0.1 el anillo exterior se fragmenta en 12 clústeres (ARI ≈ 0.58); con eps ≥ 0.4 ambos anillos se unen (ARI = 0). El rango estable es ≈ 0.15–0.35.

**Spectral con nearest_neighbors acierta (ARI = 1.0).** Cada anillo forma una componente conectada del grafo de vecinos. Con rbf y gamma ≤ 5 falla como K-means (ARI ≈ 0); con gamma = 20 funciona. Con n_neighbors = 50 conecta ambos círculos y falla (ARI ≈ 0): el número de vecinos debe ser pequeño frente a la separación entre estructuras.

### *4.2 Significado de las métricas en Circles*

| Métrica | K-means | DBSCAN | Spectral |
|---|---|---|---|
| N.º de clústeres | 2 | 2 | 2 |
| % de ruido | 0.0 | 0.0 | 0.0 |
| ARI | -0.002 | 1 | 1 |
| V-measure | 0 | 1 | 1 |
| Homogeneidad | 0 | 1 | 1 |
| Completitud | 0 | 1 | 1 |
| Silhouette | 0.33 | 0.157 | 0.157 |
| Davies-Bouldin | 1.221 | 205.776 | 205.776 |
| Calinski-Harabasz | 263.43 | 0.01 | 0.01 |

*Tabla 3. Métricas de validación en Circles.*

- **Externas:** ARI ≈ 0 y V-measure = 0 en K-means indican concordancia nula con la realidad (nivel de azar). ARI = V-measure = 1 en DBSCAN y Spectral es una agrupación perfecta.
- **Davies-Bouldin = 205.8:** divide la suma de dispersiones entre la distancia entre centroides. En círculos concéntricos ambos centroides coinciden (≈ el origen), el denominador tiende a 0 y el índice se dispara. No significa mala agrupación, sino que la métrica no es útil para clústeres anidados.
- **Calinski-Harabasz ≈ 0.01:** como los centroides coinciden, la dispersión entre clústeres es ≈ 0.
- **Silhouette 0.157 frente a 0.330:** en la agrupación correcta, los puntos del círculo interior tienen como vecino de otro clúster al anillo exterior, que no está tan lejos, y los del anillo exterior están muy distantes entre sí. K-means, al partir el plano en dos mitades, obtiene un Silhouette más alto aun estando equivocado.
- **Conclusión:** con datos concéntricos las métricas basadas en centroides (Davies-Bouldin, Calinski-Harabasz) y en distancias medias (Silhouette) favorecen a K-means y castigan a los modelos correctos.

## 5. Modelos lineales y no lineales; hiperparámetros críticos

Aquí "lineal" significa que la frontera entre clústeres es una recta o hiperplano en el espacio original, por lo que solo separa grupos compactos y convexos.

| Modelo | Naturaleza | Por qué | Hiperparámetros críticos |
|---|---|---|---|
| K-means | Lineal | Asigna cada punto al centroide más cercano; la frontera entre dos centroides es el hiperplano mediatriz (diagrama de Voronoi). Minimiza la inercia, que favorece clústeres esféricos. | n_clusters (k), n_init / init, escalado |
| DBSCAN | No lineal | Agrupa por densidad y conectividad: encadena puntos vecinos y sigue formas arbitrarias. No necesita k y detecta ruido. | eps y min_samples; muy sensible a eps y al escalado |
| SpectralClustering | No lineal | Construye un grafo de afinidad y agrupa en el espacio de autovectores del Laplaciano. | n_clusters, affinity, n_neighbors o gamma |

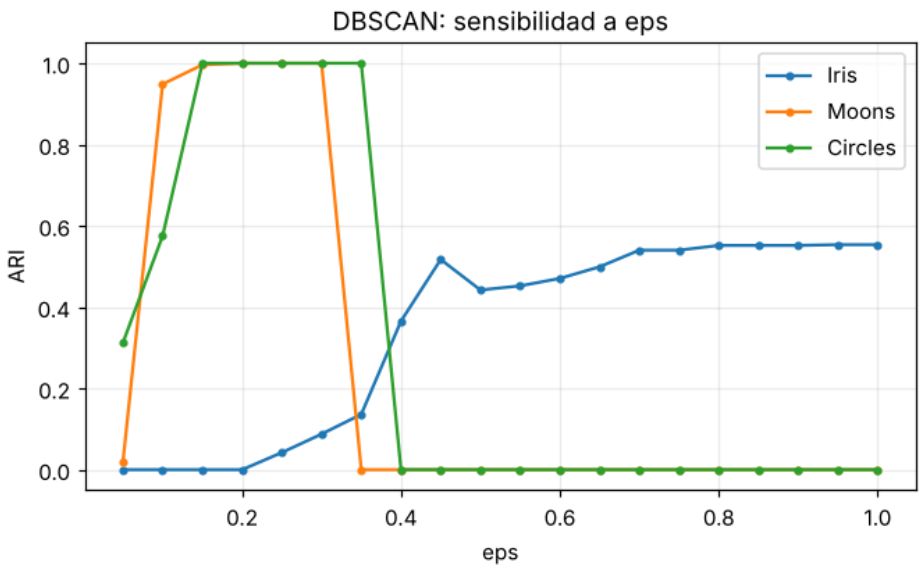



*Figura 5. Sensibilidad de DBSCAN a eps (ARI) en los tres datasets.*

### *5.1 Sensibilidad empírica a los hiperparámetros*

- **DBSCAN, eps:** demasiado pequeño genera ruido y fragmentación; demasiado grande (≥ 0.4 en Moons y Circles) fusiona todo en un clúster. En Iris ningún eps recuperó las 3 especies. El gráfico de k-distancias ayuda a elegirlo.

- **Spectral, affinity:** con rbf, un gamma pequeño (≤ 5) falla en ambos datasets sintéticos; con nearest_neighbors, 10–20 vecinos funcionan, pero 50 conecta estructuras distintas en Circles.
- **K-means, inicialización:** con inicialización aleatoria única (n_init = 1), el ARI en Iris varió entre 0.43 y 0.65 según la semilla.
- **Costos:** Spectral requiere una matriz de afinidad (costosa en datasets grandes); DBSCAN tiene dificultades con densidades heterogéneas; K-means es el más rápido pero el más restrictivo.

## 6. Resumen consolidado y conclusiones

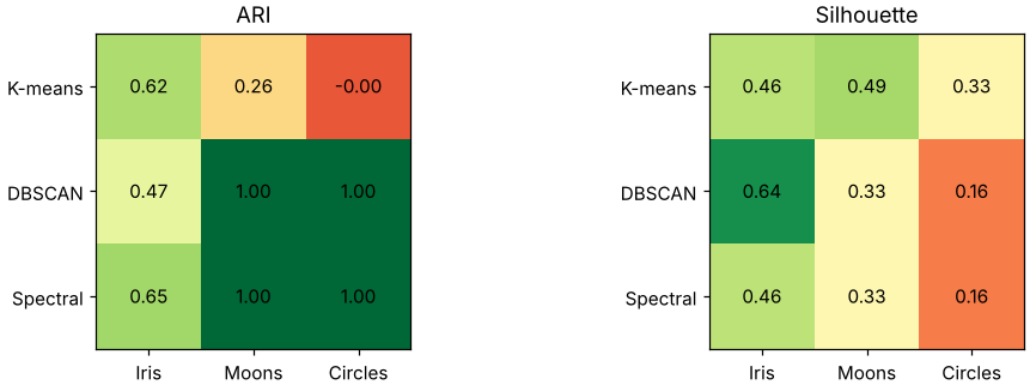



*Figura 6. ARI (externa) y Silhouette (interna) por modelo y dataset.*

**1. No existe un algoritmo mejor universal.** K-means es suficiente para grupos compactos (Iris); para formas curvas o anidadas (Moons, Circles) se necesitan métodos de densidad o de grafos (DBSCAN, Spectral).

**2. Las métricas internas pueden engañar.** En Moons y Circles el modelo equivocado (K-means) obtiene los mejores Silhouette, Davies-Bouldin y Calinski-Harabasz, y en Iris el DBSCAN con peor ARI obtiene las mejores internas. Se deben combinar métricas externas (si hay etiquetas), internas y la inspección visual. El propio material del curso advierte que por lo general no es adecuado comparar algoritmos de clúster distintos con estas medidas.

**3. Los hiperparámetros críticos** (eps, gamma / n_neighbors, k, n_init) pueden cambiar el resultado de ARI ≈ 0 a ARI = 1; deben justificarse con herramientas como el gráfico de k-distancias, el codo y barridos de sensibilidad.

## 7. Aplicación gráfica interactiva (Tkinter + Matplotlib)

Además del notebook se desarrolló una aplicación de escritorio, clustering_app.py, que permite entrenar K-means, DBSCAN y SpectralClustering sobre el dataset Circles, cambiar los hiperparámetros en vivo y ver al instante cómo cambian los clústeres y las métricas. Sirve como apoyo para la exposición: en lugar de leer una tabla, se observa cómo cada modelo separa (o mezcla) los dos anillos.

### *7.1 Arquitectura del código*

El código está organizado en capas con una responsabilidad cada una, y sigue el flujo generar datos → escalar → entrenar → predecir etiquetas → evaluar → visualizar.

| Capa | Clase / función | Responsabilidad |
|---|---|---|
| 1. Configuración | Constantes | Semilla (42), 400 puntos, noise = 0.05, factor = 0.5, paleta de colores e hiperparámetros por defecto. |
| 2. Datos | DatasetRepository | Genera Circles con make_circles y lo escala con StandardScaler. Añade z = 0 para la vista 3D. |
| 3. Modelos | ModelRunner | fit_all entrena los tres modelos y devuelve las etiquetas; elbow calcula inercia y Silhouette para k = 2 a 8. |
| 4. Métricas | Metrics | Calcula ARI y V-measure (externas), Silhouette y Davies-Bouldin (internas). Las internas ignoran el ruido de DBSCAN. |
| 5. Interfaz | App (Tk) | Controles, tres pestañas, tabla de métricas, gráfico del codo y animación 3D. |

### *7.2 Cómo ejecutarla*

- Instalar las dependencias: pip install -r requirements.txt (numpy, scikit-learn y matplotlib).
- Ejecutar: python clustering_app.py (o abrir el archivo en PyCharm y ejecutarlo).
- Tkinter viene incluido con Python en Windows y macOS. En Linux puede requerir instalar el paquete python3-tk.

### *7.3 Interfaz y funcionamiento*

La barra superior tiene cuatro campos editables: **k** (número de clústeres de K-means y Spectral), **eps** y **min_samples** (DBSCAN) y **n_neighbors** (Spectral). El botón Ejecutar reentrena los modelos con los valores escritos y el botón Pausar detiene la animación. Si algún valor es inválido, la aplicación muestra un mensaje de error en lugar de cerrarse.

- **Pestaña Clusters 3D (animado):** cuatro paneles (etiquetas reales, K-means, DBSCAN y Spectral). En la primera fase los grupos se elevan a distinta altura en el eje z, y así se distingue qué puntos asignó cada modelo a cada clúster; en la segunda fase la vista rota 360°. Los puntos de ruido de DBSCAN se pintan en gris.
- **Pestaña Métricas:** tabla con número de clústeres, puntos de ruido, ARI, V-measure, Silhouette y Davies-Bouldin de cada modelo, más un texto que explica qué significa cada métrica y por qué las internas fallan en formas no convexas.
- **Pestaña Elbow / Silhouette vs k:** método del codo y Silhouette de K-means para k de 2 a 8.

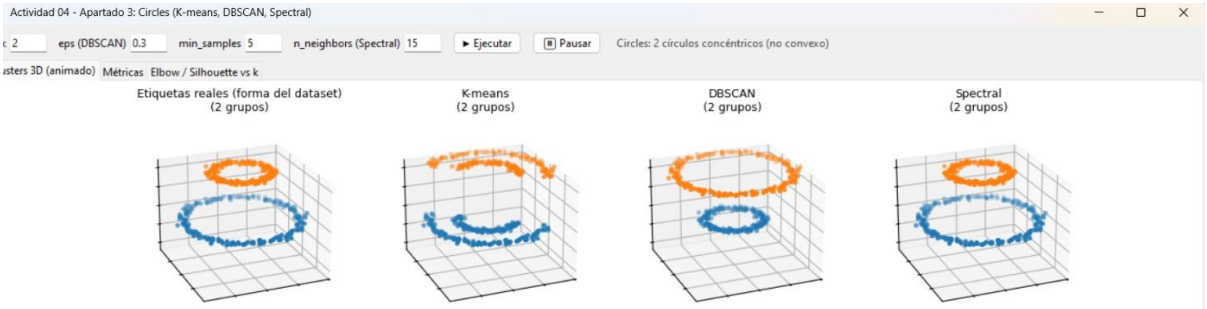



*Figura 7. Aplicación con Circles (k = 2, eps = 0.3, min_samples = 5, n_neighbors = 15). K-means mezcla los anillos; DBSCAN y Spectral los separan.*

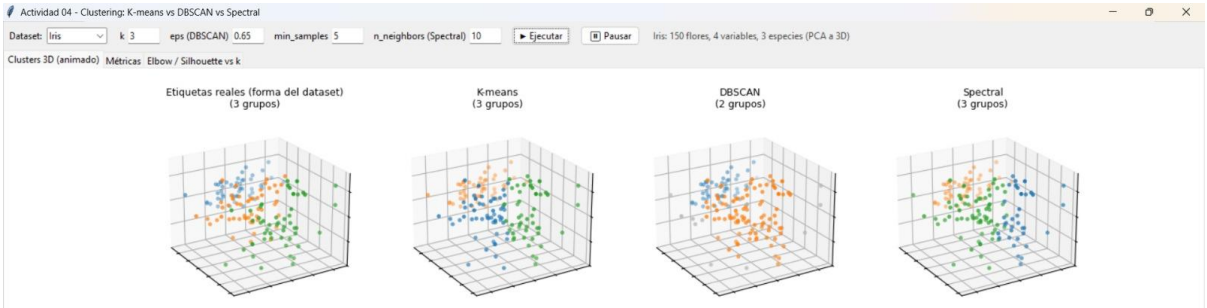



*Figura 8. Versión ampliada de la aplicación con selector de dataset, aquí con Iris (k = 3, eps = 0.65, n_neighbors = 10). DBSCAN encuentra 2 grupos y marca ruido en gris.*

### *7.4 Resultados con los parámetros por defecto*

Se ejecutaron las capas de datos, modelos y métricas de la aplicación con sus valores por defecto. Los resultados son:

| Métrica | K-means | DBSCAN | Spectral |
|---|---|---|---|
| N.º de clústeres | 2 | 2 | 2 |
| Puntos de ruido | 0 | 0 | 0 |
| ARI | -0.002 | 1 | 1 |
| V-measure | 0 | 1 | 1 |
| Silhouette | 0.354 | 0.111 | 0.111 |
| Davies-Bouldin | 1.176 | 331.956 | 331.956 |

*Tabla 4. Métricas de la aplicación en Circles (400 puntos, factor = 0.5).*

Las conclusiones son las mismas que en el notebook: K-means no distingue los anillos (ARI ≈ 0) pero obtiene el mejor Silhouette y el menor Davies-Bouldin; DBSCAN y Spectral recuperan los dos anillos exactamente (ARI = V-measure = 1) y sus métricas internas salen peores. Los valores internos difieren de la Tabla 3 (Silhouette 0.111 frente a 0.157 y Davies-Bouldin 331.956 frente a 205.776) porque la aplicación usa otra configuración del dataset (400 puntos, factor = 0.5 y datos escalados). Como los centroides de ambos anillos casi coinciden, el Davies-Bouldin divide por una distancia cercana a cero y su magnitud cambia mucho entre configuraciones sin que signifique que un resultado sea mejor que otro.

### *7.5 Sensibilidad a los hiperparámetros en la aplicación*

Cambiando los campos de la barra superior se reproduce el análisis de sensibilidad del notebook. Con los datos de la aplicación se obtuvo:

- **DBSCAN, eps:** con eps = 0.1 aparecen 17 clústeres y 254 puntos de ruido (ARI = 0.195); con eps = 0.2, 10 clústeres (ARI = 0.579); con eps entre 0.25 y 0.45 recupera los dos anillos (ARI = 1); con eps ≥ 0.5 los fusiona en un solo clúster (ARI = 0). El valor por defecto (0.3) está dentro del rango estable.
- **Spectral, n_neighbors:** con 5, 10 o 15 vecinos acierta (ARI = 1); con 3 vecinos el grafo se fragmenta (ARI ≈ 0) y con 30 o más conecta los dos anillos y falla (ARI ≈ 0).
- **K-means, k:** la inercia baja de forma continua (505 → 306 → 214 → 169 → 143 …) sin un codo claro, y el Silhouette alcanza su máximo en k = 3 (0.389), aunque el dataset tiene 2 clases reales. Esto confirma que ni el codo ni el Silhouette sirven para elegir k en formas no convexas.

### *7.6 Notas técnicas y limitaciones*

- La animación 3D modifica el atributo interno _offsets3d de Matplotlib. Es un atributo no documentado, por lo que podría cambiar en versiones futuras; el requirements.txt no

fija versiones, y para reproducir exactamente los resultados conviene usar las mismas versiones que el notebook (scikit-learn 1.9.1).

- La Figura 8 corresponde a una versión ampliada de la aplicación con selector de dataset. El archivo entregado en el repositorio, clustering_app.py, trabaja solo con Circles.
- La aplicación complementa al notebook pero no lo reemplaza: las tablas, el barrido de eps y las figuras del informe provienen del notebook.

## 8. Repositorio

**Enlace de GitHub:** https://github.com/PattyTurpo/Clustering.git